

CLASSIFICAÇÃO MULTICLASSE EM SISTEMAS DE INTERFACE CÉREBRO-MÁQUINA BASEADAS EM POTENCIAIS VISUALMENTE EVOCADOSⁱ

Fablena Kathllen Nascimento Diasⁱⁱ
Cleison Daniel Silvaⁱⁱⁱ
(Universidade Federal do Pará)

Resumo

O cérebro, como ponto central das nossas ações e pensamentos, desencadeou o desenvolvimento da Interface Cérebro-Máquina (ICM), uma ferramenta que possibilita o controle de dispositivos através da mente, particularmente benéfica para aqueles com limitações físicas. Na exploração da ICM, o foco recai sobre a interpretação da intenção do usuário por meio da monitoração da atividade elétrica cerebral que é capturada através do Eletroencefalograma (EEG). Os sistemas ICM baseados em Steady State Visually Evoked Potential (SSVEP) usam respostas cerebrais a qualquer estímulo visual piscando em uma frequência constante como comando de entrada para um aplicativo ou dispositivo externo. No âmbito da ICM-SSVEP, a primeira etapa é a aquisição do sinal, onde a atividade elétrica cerebral é registrada. Em seguida é realizado o pré-processamento e a extração de características. A etapa final é a classificação multiclasse, na qual diferentes estímulos visuais são identificados. Posteriormente, o foco se aplica na técnica de ensemble, a ideia é que a combinação entre dois classificadores supere as limitações dos classificadores observados individualmente, resultando em um desempenho preditivo mais sólido.

Palavras-chave: Interface Cérebro-Máquina, Steady State Visually Evoked Potential, Classificação Multiclasse.

Abstract

The brain, as the central point of our actions and thoughts, triggered the development of the Brain Computer Interface (BCI), a tool that enables control of devices through the mind, particularly beneficial for those with physical limitations. In exploring BCI, the focus is on interpreting the user's intention by monitoring the electrical activity of the brain that is captured through the Electroencephalogram (EEG). BCI systems based on Steady State Visually Evoked Potential (SSVEP) use brain responses to any visual stimulus flashing at a constant frequency as input command to an application or external device. Within the scope of ICM-SSVEP, the first step is signal acquisition, where brain electrical activity is recorded. Next, pre-processing and feature extraction are carried out. The final step is multiclass classification, in which different visual stimuli are identified. Subsequently, the focus applies to the ensemble technique, the idea is that the combination of two classifiers overcomes the limitations of the classifiers observed individually, resulting in a more solid predictive performance.

Keywords: Brain Computer Interface, Steady State Visually Evoked Potential, Multiclass Classification.

O cérebro humano detém funções indispensáveis e que são essenciais para o bom funcionamento do corpo, ele é responsável por coordenar as funções motoras, sensoriais e cognitivas do corpo humano. Para investigar de forma eficaz o bom funcionamento deste órgão, algumas áreas de estudos se dedicaram a desenvolver conhecimentos específicos sobre o funcionamento do cérebro humano, resultando simultaneamente a esse desenvolvimento o surgimento da Interface Cérebro-Máquina (ICM) [1].


A ICM é uma técnica que permite a comunicação direta entre o cérebro e uma máquina, permitindo que pessoas com deficiências motoras ou sensoriais possam controlar dispositivos externos. As técnicas de ICM não têm a capacidade de ler mentes ou decifrar pensamentos, em vez disso, seu objetivo é interpretar a intenção do usuário por meio do monitoramento da atividade cerebral [1].

O fenômeno neurofisiológico utilizado para decodificar a intenção do usuário da ICM pode variar, sendo o Steady-State Visually

Evoked Potential (SSVEP) o mais comum, pois é relativamente fácil de gerar e de processar os sinais resultantes. O SSVEP é gerado pela atividade neural em resposta a um estímulo visual com frequência constante e ocorre no córtex visual, localizado no lobo occipital, área responsável pela percepção visual. Quando o usuário focaliza o olhar em uma frequência de estímulo permanente é possível observar um aumento da atividade cerebral na mesma frequência e harmônicos, na região do córtex visual [2].

O cérebro reage com uma resposta elétrica na frequência correspondente ao estímulo visual que o usuário está prestando atenção. Um dos métodos utilizados para capturar os sinais cerebrais é o Eletroencefalograma (EEG) que consiste em uma técnica de neuroimagem e é definido como um método não invasivo, onde os sinais elétricos são coletados por eletrodos em contato com couro cabeludo. Esses sinais representam o fluxo de correntes elétricas que são observáveis durante as excitações sinápticas neurais [3]. Cada eletrodo é posicionado no escalpo de acordo com o padrão 10-10 de posicionamento internacional, como apresentado na Figura 1.

Figura 1 - Mapeamento com a localização e a nomenclatura dos eletrodos intermediários de 10%.



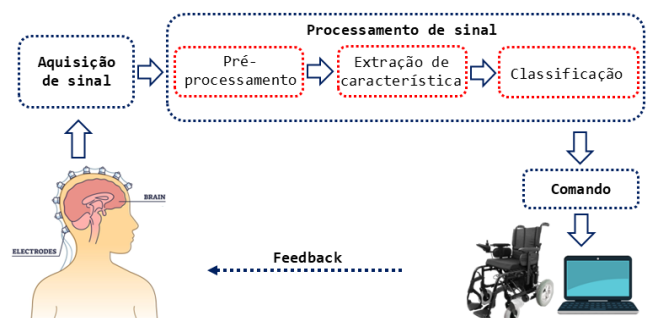
Fonte: Sociedade Americana de Eletroencefalografia.

O propósito fundamental dos sistemas ICM-SSVEP é processar os sinais cerebrais para discernir o estímulo visual escolhido pelo usuário. Para isso, o ICM segue etapas

padronizadas, essas etapas são claramente delineadas na Figura 2, representando o ciclo de processamento característico nos sistemas de ICM-SSVEP:

- **Aquisição do Sinal:** Nesta etapa, realiza-se a captura da atividade elétrica cerebral do usuário, fundamental para compreender a resposta cerebral ao estímulo visual.
- **Pré-processamento:** Consiste na remoção de elementos considerados ruído no sinal, contribuindo para aprimorar a qualidade e a confiabilidade das informações obtidas.
- **Extração de Características:** Aqui, são identificados e isolados os trechos de interesse nos sinais, focalizando apenas nas informações relevantes para a tarefa de classificação subsequente.
- **Classificação:** Nessa fase crítica, busca-se associar os atributos extraídos nas etapas anteriores com as possíveis classes, permitindo a identificação precisa do estímulo visual escolhido pelo usuário.

Figura 2 - Etapas de um sistema Interface Cérebro-Máquina.



Fonte: Autoria própria, 2023.

Uma das questões amplamente exploradas em aprendizado de máquina refere-se à classificação de padrões. Em uma abordagem simplificada, a classificação de padrões envolve a atribuição de cada padrão disponível a uma das classes presentes na aplicação [4]. Em outras palavras, quando apresentado a um vetor de atributos, o classificador deve produzir como resultado o rótulo que indica a classe à qual o padrão pertence. Em um contexto específico, como o de sistemas de ICM-SSVEP, o objetivo do classificador é discernir a frequência do

estímulo à qual o usuário está concentrado com base em seus sinais cerebrais.

Para auxiliar esse processo, o método de Análise de Correlação Canônica (CCA) é amplamente utilizado devido capacidade de escalabilidade e fácil implementação. Nesse contexto, o método CCA, quando aplicado a SSVEP, utiliza sinais senoidais genéricos (seno e cosseno) como referência. Essa abordagem permite a detecção de componentes associados aos sinais originais de EEG e abrange variações de fase, otimizando, assim, a correlação entre os sinais de EEG e as referências [5].

Método

O conjunto de dados empregado nesta pesquisa consiste em sinais baseados em SSVEP offline, coletados de dez voluntários saudáveis e disponíveis em um repositório público¹. Segundo a documentação, os dados abrangem informações de 10 indivíduos saudáveis (9 homens e 1 mulher, média de idade: 28 anos) com visão normal ou corrigida para normal, que participaram do estudo. O registro de EEG foi realizado utilizando oito eletrodos Ag/AgCl, cobrindo a região occipital, por meio do sistema BioSemi² ActiveTwo EEG.

No experimento, foram utilizadas 12 diferentes frequências de estimulação SSVEP (9.25, 11.25, 13.25, 9.75, 11.75, 13.75, 10.25, 12.25, 14.25, 10.75, 12.75, 14.75), e cada sujeito teve acesso a 15 arquivos distintos para cada estímulo de frequência, representando diferentes tentativas. Os dados adquiridos incluem oito sinais de EEG, sendo que, para esta pesquisa, foram utilizados apenas três canais específicos. Conforme indicado na documentação, a frequência de amostragem do experimento é de 256 Hz, proporcionando 256 amostras por segundo em cada eletrodo. A duração total do experimento é de 4 segundos por tentativa.

Os estímulos visuais, SSVEP, tendem a modular a atividade elétrica cerebral na mesma frequência do estímulo, desta forma, a detecção

de estímulos na frequência F_0 pode ser realizada filtrando os sinais de EEG numa banda de frequência centrada em torno de F_0 . Para garantir a qualidade dos resultados, uma vez que ao coletar o sinal de EEG é natural a presença de ruídos, e preservar as informações espectrais entorno do estímulo é comum utilizar filtros passa-banda. Os filtros necessitam de parâmetros que definem a banda de frequências de interesse, como o intervalo $\Delta f = [F_l, F_u]$, onde F_l e F_u representam as frequências de corte inferior e superior em *Hertz*, respectivamente, centrado na frequência de estímulo [3]. Filtros passa-banda *butterworth* de 5ª ordem são utilizados para selecionar as frequências compendiadas por Δf .

Após a etapa de filtragem, procede-se com a extração de épocas, que consiste em dividir os dados cerebrais em intervalos de tempo específicos, conhecidos como épocas, para análises subsequentes. A escolha dessas épocas é orientada pelos eventos relacionados à tarefa ou estímulo que o usuário está executando. Essa preparação é fundamental para a aplicação eficaz do método de Análise de Correlação Canônica (CCA), desempenhando um papel crucial no facilitamento do processo de classificação dos sinais de EEG. Fundamentado no conceito de correlação linear, que avalia a magnitude da semelhança linear entre dois conjuntos de dados, X e Y [6], o método CCA explora essa métrica para discernir padrões relevantes. Se a semelhança entre os conjuntos for crescente, indica correlação; se for neutra, não há correlação; por fim, se os valores de X crescem enquanto os de Y decrescem, denota uma anticorrelação. Nesse contexto, o método CCA busca identificar vetores de peso, representados por W_x e W_y , que maximizam a relação entre os conjuntos X e Y ao resolver a equação:

$$\rho(x, y) = \max_{w_x, w_y} \frac{E[w_x^T X Y^T w_y]}{\sqrt{E[w_x^T X X^T w_x] E[w_y^T Y Y^T w_y]}} \quad (1)$$

Após a aplicação do método do CCA, aplica-se o periodograma que estima a densidade espectral de um sinal. Isso revela as relações entre a amplitude e a frequência do sinal, sendo uma técnica

¹<https://github.com/IzicTemi/SSVEP-Psychopy/tree/main>

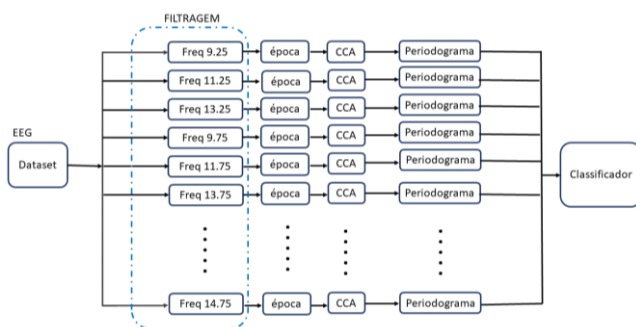
² <https://www.biosemi.com/products.htm>

amplamente utilizada em diversas análises baseadas em EEG [7]. Para calcular o periodograma do sinal de EEG discreto filtrado $x[n]$, faz-se uso da equação:

$$\hat{P}(k) = \frac{1}{N} \left| \sum_{n=0}^{N-1} x[n] e^{-j \frac{2\pi}{N} nk} \right|^2, \forall k = 0, 1, \dots, N-1 \quad (2)$$

P representa o periodograma, k é o ordinal no domínio da frequência, n é o ordinal no domínio do tempo discreto, o comprimento da sequência a ser transformada é descrito por N [7]. Ambas as funções são definidas em relação à frequência do estímulo. Em outras palavras, o CCA receberá informações dos sinais filtrados relacionados aos sinais de EEG, enquanto o periodograma receberá informações referentes aos dados de saída do CCA. O diagrama do processo pode ser visualizado na Figura 3.

Figura 3 - Diagrama da etapa de extração de características.



Fonte: Autoria própria, 2023.

Na fase de classificação, os modelos são avaliados de maneira isolada e consiste nos seguintes classificadores:

- Análise Discriminante Linear (LDA), é um método estatístico utilizado para encontrar a combinação linear de características que melhor separam duas ou mais classes em um conjunto de dados. O LDA busca maximizar a distância entre as médias das classes enquanto minimiza a dispersão intraclasse.
- k-Nearest Neighbors (k-NN), é um algoritmo de classificação simples e intuitivo. Ele opera com base na proximidade entre os pontos de dados em

um espaço multidimensional. O k-NN classifica uma instância desconhecida atribuindo a ela a classe mais comum entre seus k vizinhos mais próximos, onde k é um parâmetro definido pelo usuário.

- Máquina de Vetores de Suporte (SVM), é um poderoso algoritmo de aprendizado de máquina utilizado para tarefas de classificação e regressão. O SVM funciona encontrando o hiperplano que melhor separa as classes em um espaço de características. O "melhor" hiperplano é aquele que maximiza a margem entre as classes, sendo a margem a distância entre o hiperplano e os pontos mais próximos de cada classe, conhecidos como vetores de suporte.
- Gradient Boosting Classifier (GB), é um algoritmo de aprendizado de máquina que pertence à família de métodos de boosting. Ele cria um modelo preditivo forte combinando a contribuição de vários modelos mais fracos, geralmente árvores de decisão rasas.
- LightGBM (Light Gradient Boosting Machine), é uma implementação eficiente e de alta performance do algoritmo de Gradient Boosting, projetado para lidar com grandes volumes de dados e conjuntos de dados de alta dimensionalidade.
- Random Forest (RF), é um algoritmo de aprendizado de máquina baseado em ensemble que opera construindo uma coleção (ou "floresta") de árvores de decisão.

Posteriormente, o foco recai sobre a aplicação de duas técnicas de ensemble: Random Forest (RF) e LightGBM (Light Gradient Boosting Machine). Esses métodos são escolhidos estrategicamente para combinar as previsões dos classificadores individuais, explorando a complementaridade e a robustez desses modelos. A ideia inicial é que a combinação entre Random Forest e LightGBM pode superar as limitações dos classificadores observados individualmente, resultando em um desempenho preditivo mais sólido e confiável para o problema em questão.

Resultados

Com base no conjunto de dados e nos métodos utilizados, este trabalho foi dividido em dois momentos. O primeiro momento constituiu na obtenção da classificação dos sinais pelos classificadores LDA, KNN, SVM e RF. A Tabela 1 exibe as acurácias de cada sujeito para a classificação das doze frequências.

Tabela 1 - Acurácia de todos os sujeitos para os classificadores: LDA, KNN, SVM e RF.

SUJEITO	LDA	KNN	SVM	RF
SUJ01	23.46%	24.07%	19.75%	29.63%
SUJ02	22.84%	17.28%	9.26%	18.52%
SUJ03	38.27%	25.93%	17.28%	29.63%
SUJ04	63.58%	35.80%	46.30%	50.00%
SUJ05	62.96%	34.57%	15.43%	66.05%
SUJ06	60.49%	40.12%	41.98%	56.17%
SUJ07	39.51%	25.93%	27.16%	35.80%
SUJ08	90.12%	80.25%	83.33%	92.59%
SUJ09	31.48%	37.65%	29.63%	50.62%
SUJ10	50.00%	17.28%	9.88%	56.17%

Fonte: Autoria própria, 2023.

Conforme a Tabela 1, é evidente que o SUJ08 se destaca, apresentando uma acurácia excepcionalmente elevada em todos os classificadores, indicando uma resposta robusta aos estímulos visuais. Notavelmente, os sujeitos SUJ02, SUJ03, SUJ04, SUJ06 e SUJ07 alcançaram desempenho superior no classificador LDA, atingindo até 63.58% de acurácia. Em contrapartida, os sujeitos SUJ01, SUJ05, SUJ08, SUJ09 e SUJ10 possuem melhor assertividade para o classificador RF chegando à 92.52%.

O segundo momento implementou-se na classificação utilizando GB, LGBM e o método de Ensemble (combinação de RF e LGBM). A Tabela 2 exibe as acurácias de cada sujeito para a classificação das doze frequências.

Tabela 2 - Acurácia de todos os sujeitos para os classificadores: BG, LGBM e o método de Ensemble.

SUJEITO	BG	LGBM	ENSEMBLE
SUJ01	20.99%	19.75%	24.07%
SUJ02	19.14%	20.37%	17.90%
SUJ03	28.40%	31.48%	31.48%
SUJ04	45.06%	53.09%	51.85%
SUJ05	66.67%	67.28%	66.67%
SUJ06	56.17%	56.79%	54.94%
SUJ07	35.80%	35.80%	39.51%
SUJ08	91.98%	91.98%	92.59%
SUJ09	47.53%	51.85%	50.62%
SUJ10	53.09%	51.23%	54.94%

Fonte: Autoria própria, 2023.

De acordo com a análise da Tabela, observa-se que o SUJ08 alcança, novamente, uma notável acurácia elevada em todos os classificadores. Destaca-se que o classificador BG também demonstra um bom desempenho. Vale ressaltar que os classificadores LGBM e Ensemble exibem desempenhos bastante semelhantes na maioria dos casos, visto que o Ensemble é uma combinação dos classificadores RF e LGBM. No entanto, é interessante notar que, para os sujeitos SUJ02, SUJ03, SUJ04, SUJ05, SUJ06 e SUJ09, o classificador LGBM supera ligeiramente o Ensemble. Para os demais sujeitos, o método de ensemble mostra-se mais assertivo. Esses resultados reforçam a importância de considerar a variabilidade individual ao escolher métodos de classificação e ressaltam que, em determinadas situações, abordagens individuais podem superar ou igualar o desempenho de métodos de ensemble.

Discussão

Este estudo conduziu uma classificação multiclasse para 12 frequências distintas, especialmente aplicada ao paradigma de Interface Cérebro-Máquina (ICM) baseado em Potenciais Evocados Visualmente em Estado Estacionário (SSVEP). Para adquirir dados, foram utilizados 3 eletrodos posicionados no lobo occipital, e a

estratégia de extração de épocas configurou-se com segmentos temporais de 2 segundos e uma sobreposição de 50%. O método de Análise de Correlação Canônica (CCA) foi implementado como parte fundamental desse processo.

Essas decisões metodológicas foram cuidadosamente orientadas por insights provenientes de estudos na literatura especializada e de trabalhos desenvolvidos anteriormente. O uso conjunto do CCA e das técnicas de classificação reforça a abordagem integrada deste estudo, contribuindo para uma compreensão mais aprofundada dos mecanismos subjacentes a esse tipo específico de ICM.

Implementou-se diversos classificadores, incluindo LDA, KNN, SVM, RF, BG, LGBM e Ensemble (combinação dos classificadores RF e LGBM). Cada sujeito foi submetido a uma variedade de estímulos visuais, e os resultados forneceram insights valiosos sobre a eficácia desses métodos.

Ao avaliar a acurácia dos classificadores individualmente, destaca-se o notável desempenho do SUJ08 em todos os casos. Os sujeitos SUJ02, SUJ03, SUJ04, SUJ06 e SUJ07 apresentaram melhor desempenho com o classificador LDA, enquanto SUJ01, SUJ05, SUJ08, SUJ09 e SUJ10 mostraram melhor desempenho com o RF. O classificador BG também demonstrou um bom desempenho, enquanto LGBM e Ensemble apresentaram desempenhos semelhantes na maioria dos casos, ressaltando que o Ensemble é uma combinação dos classificadores RF e LGBM.

Explorando técnicas de ensemble, observou-se que o SUJ08 manteve um desempenho excepcional em todas as instâncias. Os resultados sugerem que, em muitos casos, o LGBM superou ligeiramente o Ensemble, mas os métodos de ensemble mostraram desempenho robusto na maioria dos sujeitos.

Esses resultados reforçam a importância de considerar a variabilidade individual ao escolher métodos de classificação e ressaltam que, em determinadas situações, abordagens individuais podem superar ou igualar o desempenho de métodos de ensemble.

Esta abordagem integrada, empregando

métodos como Análise de Correlação Canônica (CCA) e ensemble, fortalece a compreensão dos mecanismos subjacentes a este tipo específico de ICM. O estudo não apenas contribui para o avanço da pesquisa em SSVEP-ICM, mas também destaca a importância de considerar diferentes classificadores e técnicas de ensemble para alcançar desempenho preditivo sólido e confiável.

Referências

- [1] J. P. G. Souza et al. **“Interface Cérebro-Máquina (ICM): Da transdução do estímulo externo em impulso nervoso a tradução em comandos digitais”**. In: Caderno De Graduação - Ciências Biológicas e da Saúde - UNIT/AL 3 (2015), pp. 139–152.
- [2] G. Garcia-Molina and D. Zhu. **“Optimal spatial filtering for the steady state visual evoked potential: BCI application”**. In: 5th International IEEE/EMBS Conference on Neural Engineering (2011). doi: 10.1109/ner.2011.5910512.
- [3] Vilas Boas, V. M. (2021) **“AutoBCI: interface cérebro-máquina com configuração hiperparamétrica automatizada”**. Orientador: Cleison Daniel Silva; Coorientador: Otávio Noura Teixeira. 2021. 249 f. Dissertação (Mestrado em Computação Aplicada) - Núcleo de Desenvolvimento Amazônico em Engenharia, Universidade Federal do Pará, Tucuruí, 2021. Disponível em: <http://repositorio.ufpa.br/jspui/handle/2011/1321>.
- [4] GRANZOTTI, Rafael Aparecido. **Extração de características via autoencoders aplicada a interfaces cérebro-computador baseadas em potenciais evocados visualmente em regime estacionário**. 2020. Tese de Doutorado

- [5] MA, Pengfei et al. **A classification algorithm of an SSVEP brain-Computer interface based on CCA fusion wavelet coefficients**. Journal of Neuroscience Methods, v. 371, p. 109502, 2022.
- [6] BROGIN, João Angelo Ferres. **Generalização da técnica de correlação canônica para aplicações em interface cérebro-máquina**. 2018.
- [7] Mohammad Samin Nur et al. CHOWDHURY. **“Deep neural network for visual stimulus-based reaction time estimation using the periodogram of single-trial eeg”**. In: Sensors 20.21 (2020), p. 6090.

ⁱ Trabalho desenvolvido com o apoio do Programa de Iniciação Tecnológica em TICs/CNPq.

ⁱⁱ Discente de Engenharia de Computação da Universidade Federal do Pará. Bolsista CNPq.
E-mail: fablena_dias@hotmail.com.

ⁱⁱⁱ Docente da Faculdade de Engenharia Elétrica, Universidade Federal do Pará.
E-mail: cleison@ufpa.br.

Parecer do Orientador

Tucuruí, 22 de dezembro de 2023

Cleison Daniel Silva